# Self drives me crazy: from 0 to autonomous car in 150 hours



Paula Moraes

#### **Quem somos:**

- Felipe Salvatore: doutorando em Deep Learning/NLP
- Paula Moraes: mestranda com foco em Robótica Probabilística



#### Por que montar um carro autônomo?

- Desmistificar a implementação dessa tecnologia
- Porque é divertido :)



#### **Desafio**

Implementar o artigo: End to End Learning for Self-Driving Cars (2016)


#### Por que carros autônomos?

 Carros autônomos são os robôs que vão diretamente impactar nosso dia a dia no futuro próximo: atualmente há 51,3 milhões de veículos rodando no Brasil.

 Esse problema é rico para a inteligência artificial, pois junta diferentes áreas como machine learning, computer vision, path planning e reinforcement learning

#### Por que carros autônomos?

**DeepTraffic:** Deep Reinforcement Learning



Fonte: MIT 6.S094: Deep Learning for Self-Driving Cars

#### Carro autônomo no Brasil: um breve histórico



## **End to End Learning for Self-Driving Cars**




Figure 4: CNN architecture. The network has about 27 million connections and 250 thousand parameters.

Fonte: End to End Learning for Self-Driving Cars - Bojarski, M., et al.

#### Recursos utilizados

Webcam

Power bank

**Lego NXT** 

Raspberry Pi

custo total: \$ 60







#### Robô com acionamento diferencial


- Sistema com duas rodas controladas por atuadores independentes
- Possui uma roda passiva (castor wheel) para maior estabilidade
- Benefícios:
  - simplicidade
  - permite girar no próprio eixo
- Movimentação baseada na diferença de velocidade entre os motores



#### Robô com acionamento diferencial








```
self.leftMotor = nxt.Motor(self.brick, nxt.PORT_B)
self.rightMotor = nxt.Motor(self.brick, nxt.PORT A)
self.both = nxt.SynchronizedMotors(self.leftMotor,
                                   self.rightMotor,
                                   turn ratio)
def move_up(self):
    self.both.run(self.power up)
def move left(self):
    Execute action of moving left for tacho left degrees
    self.rightMotor.weak_turn(self.power_left, self.tacho_left)
    self.leftMotor.weak turn(- self.power left, self.tacho left)
def move_right(self):
    Execute action of moving rigth for tacho right degrees
    self.rightMotor.weak turn(- self.power right, self.tacho right)
    self.leftMotor.weak turn(self.power right, self.tacho right)
```

#### Controle como regressão






#### **Exemplos:**

Udacity's Lincoln MKZ


DeepTesla

## Classificação de imagens




Fonte: Fashion-mnist: a novel image dataset for benchmarking machine learning algorithms- Xiao, K., et al.

# Controle como classificação de imagens




#### **Pipeline** Image [108.0] $p(y=\uparrow | x; \theta)$ DFN Take vector or picture CNN 45.0 $3\times 1$ $10800 \times 1$ 45x80x3 Predicted action Perform action


#### Coleta de dados




#### Coleta de dados



#### Coleta de dados





# Manipulação de imagens





Original

Binary



Random shadow





Grayscale



Gaussian Blur 5x5

# **Data pipeline**





#### **Resultados com DFN**

architecture	preprocessing	hit rate ↑	hit rate $\leftarrow$	hit rate $\rightarrow$
[3]	none	0.80	0.76	0.68
[2350, 3]	none	0.80	0.70	0.80
[1333, 200, 3]	none	0.79	0.82	0.67
[3]	binarization	0.75	0.87	0.64
[233, 3]	binarization	0.72	0.85	0.82
[1628, 47, 3]	binarization	0.71	0.90	0.84

#### **Resultados com CNN**

architecture	preprocessing	hit rate ↑	hit rate $\leftarrow$	hit rate $\rightarrow$
[(24,5),731,3]	none	0.80	0.71	0.73
[(32,5),(64,5),3]	none	0.82	0.80	0.66
[(24,5),(36,5),(64,5),200,3]	none	0.76	0.84	0.72
[(24,5),456,3]	binarization	0.79	0.86	0.67
[(32,5),(64,5),3]	binarization	0.78	0.80	0.73
[(24,5),(36,5),(64,5),200,3]	binarization	0.79	0.83	0.73

# Confusion matrix of 5682 examples accuracy = 0.790567

- 2000

- 1750

- 1500


- 1250

- 1000

- 750

- 500


- 250



# Simulação



## **Primeira Tentativa**




#### **PROBLEMA:** dados pouco informativos


Comando "ir para frente" estava fortemente associado ao robô estar centralizado na pista




#### Nova coleta de dados




#### Nova coleta de dados



#### Nova coleta de dados



# Nova coleta de dados: + 13403 imagens




# **PROBLEMA:** predição x controle

#### captura e processamento de imagem ~ 9 ms

command	time
<b>†</b>	$0.06 \mathrm{\ s}$
<b>←</b>	0.29 s
$\rightarrow$	0.29 s

architecture	preprocessing	inference time
[3]	none	$0.43 \mathrm{\ s}$
[1333, 200, 3]	none	$1.35 \mathrm{\ s}$
[(24,5),731,3]	none	1.41 s
[3]	binarization	$0.42 \mathrm{\ s}$
[233, 3]	binarization	$0.59 \mathrm{\ s}$
[(32,5),(64,5),3]	binarization	$0.89 \mathrm{\ s}$
[(24,5),(36,5),(64,5),200,3]	binarization	1.24 s

Confusion matrix of 10001 examples accuracy = 0.842616



Melhor modelo: [(36, 5), 3]

imagens RGB

2500

2000

1500


1000

500


uma camada de convolução:
36 filtros 5x5

- uma camada de pooling 2x2
- sem camadas escondidas
- tempo de inferência: 0.69 s

# Modo autônomo - pista de treino



#### Pista de teste



# Modo autônomo - pista de teste



#### Próximos passos

- Experimentar novos modelos de direção, e.g. modelo Ackerman
- Integrar o robô com outros sensores:
  - GPS e Radar
- Detecção de obstáculos
- Path planning
  - Planejar trajetórias do ponto A ao ponto B

#### Conclusão

- Machine learning em aplicações reais é mais complicada do que em ambientes simulados
- Começar com deep learning para carro autônomo é fácil
- É possível implementar técnicas avançadas com hardware de baixo custo
- Variabilidade na coleta de dados é essencial
- O protótipo apresentado pode ser uma solução viável a disciplinas de inteligência artificial que desejem ir além de toy problems

#### Referências

- Artigo no Medium (@project\_m)
  - Self drives me crazy: from 0 to autonomous car in 150 hours
- Código no GitHub
  - Self-Driving Pi Car
- Dataset
  - Self-Driving Data
- Curso do MIT:
  - Deep Learning for Self-Driving Cars

## Agradecimentos





# Obrigado